

ĐẠI HỌC KINH TẾ QUỐC DÂN
KHOA TOÁN KINH TẾ

-----***-----



BÀI TẬP LỚN
KHOA HỌC DỮ LIỆU TRONG KINH TẾ VÀ KINH DOANH
ĐỀ TÀI: XÂY DỰNG VÀ KIỂM THỬ CHIẾN LƯỢC GIAO DỊCH
BẰNG HỌC MÁY

Giảng viên: Ths. Lương Văn Long

Nhóm thực hiện : 10

Lớp: Toán kinh tế 65

Hà Nội, 2026

Mục lục

BẢNG PHÂN CÔNG THÀNH VIÊN NHÓM.....	4
DANH MỤC BẢNG BIỂU	5
DANH MỤC HÌNH ẢNH.....	6
TÓM TẮT.....	7
I. GIỚI THIỆU BÀI NGHIÊN CỨU.....	8
1. Bối cảnh nghiên cứu	8
2. Tổng quan nghiên cứu	8
3. Mục tiêu nghiên cứu	9
4. Câu hỏi nghiên cứu	10
5. Đối tượng, phạm vi và đóng góp của nghiên cứu	10
II. DỮ LIỆU VÀ TIỀN XỬ LÝ	11
1. Mô tả dữ liệu nghiên cứu.....	11
2. Quy trình tiền xử lý dữ liệu.....	12
3. Trực quan hóa dữ liệu	15
4. Tập dữ liệu sau xử lý.....	17
III. PHƯƠNG PHÁP NGHIÊN CỨU	17
1. Quy trình nghiên cứu tổng quát	17
2. Xây dựng đặc trưng kỹ thuật.....	17
3. Kiểm định tính dừng và sàng lọc feature	19
4. Xây dựng biến mục tiêu	20
5. Chiến lược chia train–test theo thời gian	20
6. Mô hình nghiên cứu	21
7. Chỉ tiêu đánh giá mô hình.....	23
8. Thiết kế chiến lược giao dịch.....	25
9. Phương pháp backtest và chỉ tiêu tài chính.....	28
IV. KẾT QUẢ NGHIÊN CỨU.....	29
1. Kết quả kiểm định dữ liệu và đặc trưng.....	29
1.2. Kết quả sàng lọc đặc trưng và quy mô dữ liệu sau xử lý.....	30
2. Kết quả mô hình phân loại	31
3. Kết quả chiến lược giao dịch Smart HODL.....	32
4. Kiểm tra độ bền của mô hình và chiến lược	34
5. Đánh giá tổng hợp kết quả nghiên cứu	35

V. KẾT LUẬN VÀ ĐÁNH GIÁ	36
1. Kết luận chính của nghiên cứu.....	36
2. Đánh giá điểm mạnh của nghiên cứu.....	36
3. Những điểm còn hạn chế	36
VI. HƯỚNG PHÁT TRIỂN	37
1. Hoàn thiện quy trình đánh giá ngoài mẫu	37
2. Bổ sung chỉ tiêu đánh giá mô hình.....	37
3. Mở rộng tập đặc trưng	37
4. Nâng cấp lớp chiến lược giao dịch	37
5. Tiếp cận theo hướng nghiên cứu nhỏ.....	37
TÀI LIỆU THAM KHẢO	37

BẢNG PHÂN CÔNG THÀNH VIÊN NHÓM

Thành viên	Mã sinh viên	Tỷ trọng	Công việc phụ trách khái quát
Vũ Quốc Tấn	11233248	25%	Phụ trách thiết kế chiến lược và backtest: xây dựng logic Smart HODL, triển khai backtest, tính Final Equity, Total Return, CAGR, Sharpe Ratio, Maximum Drawdown, Win Rate và kiểm tra độ bền chiến lược.
Bùi Văn Thái	11233249	22%	Phụ trách xây dựng mô hình học máy: chuẩn bị tập dữ liệu đầu vào cho mô hình, triển khai Logistic Regression và XGBoost, tổng hợp các chỉ tiêu accuracy, log-loss, precision, recall, F1-score và confusion matrix.
Phạm Trường Phát	11233243	19%	Phụ trách dữ liệu và tiền xử lý: mô tả bộ dữ liệu ETHUSDT, xử lý timestamp, volume bằng 0, resample, tính log-return, chuẩn bị dữ liệu cho bước feature engineering.
Trần Anh Quân	11233244	19%	Phụ trách trực quan hóa và viết kết quả: xây dựng các biểu đồ dữ liệu ban đầu, trực quan hóa kết quả mô hình và chiến lược, viết phần kết quả nghiên cứu, kết luận và hướng phát triển.
Ngô Quốc An	11233194	15%	Phụ trách hỗ trợ tạo các đặc trưng kỹ thuật, kiểm định JB/ADF, sàng lọc feature, đồng thời tổng hợp tài liệu tham khảo, định dạng báo cáo, mục lục, danh mục bảng biểu và hình ảnh.

DANH MỤC BẢNG BIỂU

STT	Tên bảng	Trang
Bảng 2.1	Mô tả các biến trong bộ dữ liệu gốc	11
Bảng 2.2	Tổng hợp chỉ tiêu mô tả bộ dữ liệu	11
Bảng 2.3	Tổng hợp quy trình tiền xử lý dữ liệu	12
Bảng 4.1	Kết quả kiểm định Jarque–Bera đối với chuỗi log-return	29
Bảng 4.2	Kết quả kiểm định ADF cho chuỗi giá gốc và các đặc trưng chính	30
Bảng 4.3	Quy mô dữ liệu trước và sau quá trình xử lý	30
Bảng 4.4	Kết quả so sánh hai mô hình phân loại	31
Bảng 4.5	Các chỉ số đánh giá phân loại bổ sung của XGBoost trên tập kiểm tra	31
Bảng 4.6	So sánh hiệu quả Smart HODL và Buy & Hold trên tập kiểm tra	33
Bảng 4.7	Kết quả kiểm tra overfit của mô hình XGBoost	34
Bảng 4.8	Tóm tắt kết quả kiểm tra độ bền của chiến lược	34

DANH MỤC HÌNH ẢNH

STT	Tên hình	Trang
Hình 2.1	Mình chứng “Fat-tails”: Dữ liệu thực tế vượt xa hơn phân phối chuẩn	14
Hình 2.2	Diễn biến giá ETHUSDT và khối lượng giao dịch theo thời gian	15
Hình 2.3	Diễn biến lợi suất logarit theo thời gian	16
Hình 2.4	Phân phối của lợi suất logarit	16
Hình 4.1	Confusion Matrix của mô hình XGBoost trên tập kiểm tra	32
Hình 4.2	Đường diễn biến giá trị tài khoản của Smart HODL so với Buy & Hold và biểu đồ drawdown của chiến lược	33
Hình 4.3	Heatmap lợi nhuận (%) theo SMA Window và Trailing Stop	35

TÓM TẮT

Nghiên cứu này xem xét khả năng xây dựng một chiến lược giao dịch định lượng cho cặp ETHUSDT trên dữ liệu nến 30 phút thông qua kết hợp giữa phân tích dữ liệu chuỗi thời gian, xây dựng đặc trưng kỹ thuật, mô hình học máy có giám sát và cơ chế backtest có quản trị rủi ro. Trọng tâm của nghiên cứu không nằm ở việc dự báo chính xác mức giá tuyệt đối, mà ở việc chuyển đổi ra của mô hình thành tín hiệu giao dịch có khả năng tạo giá trị kinh tế trên dữ liệu ngoài mẫu.

Bộ dữ liệu sử dụng gồm 100.222 quan sát với sáu biến cơ bản: thời gian, giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa và khối lượng giao dịch. Sau khi làm sạch dữ liệu, xử lý volume bằng 0, tạo log-return và xây dựng các đặc trưng như Returns, RSI, PPO, PPO_Hist, BB_PctB, ATR_Pct, Vol_Ratio, các biến trễ và biến thời gian chu kỳ, tập dữ liệu dùng cho mô hình còn 100.201 quan sát.

Kết quả kiểm định cho thấy chuỗi giá đóng cửa thô không dừng, trong khi các đặc trưng đã biến đổi đáp ứng tốt hơn điều kiện dừng. Kết quả mô hình cho thấy XGBoost có độ chính xác kiểm tra 53,34%, cao hơn mức 52,89% của Logistic Regression, đồng thời log-loss trên tập kiểm tra ở mức 0,6903.

Khi xác suất dự báo của XGBoost được chuyển hóa thành chiến lược Smart HODL với bộ lọc xu hướng, stop-loss, trailing stop và ngưỡng xác suất mua/bán, chiến lược đạt Final Equity 34.481 USDT từ vốn đầu 10.000 USDT, tương ứng tổng lợi nhuận 244,81%, CAGR 105,98%, Sharpe Ratio 1,56 và Maximum Drawdown -56,99%. So với Buy & Hold trên cùng giai đoạn, Smart HODL vượt trội cả về lợi nhuận lẫn chất lượng lợi nhuận.

I. GIỚI THIỆU BÀI NGHIÊN CỨU

1. Bối cảnh nghiên cứu

Trong những năm gần đây, sự phát triển nhanh của thị trường tài sản số đã tạo ra nhiều hướng ứng dụng mới cho khoa học dữ liệu, đặc biệt trong lĩnh vực phân tích, dự báo và hỗ trợ ra quyết định đầu tư. So với nhiều thị trường tài chính truyền thống có thời gian giao dịch giới hạn, thị trường tiền mã hóa hoạt động liên tục 24 giờ mỗi ngày và 7 ngày mỗi tuần, đồng thời có mức biến động giá lớn và sự thay đổi trạng thái diễn ra rất nhanh. Những đặc điểm này khiến thị trường trở thành một môi trường phù hợp để nghiên cứu các phương pháp xử lý dữ liệu chuỗi thời gian và xây dựng chiến lược giao dịch định lượng.

Trong số các cặp giao dịch phổ biến trên thị trường tiền mã hóa, ETHUSDT được lựa chọn làm đối tượng nghiên cứu vì có thanh khoản cao, dữ liệu giao dịch liên tục và phản ánh khá rõ đặc trưng biến động của nhóm tài sản số. Bên cạnh đó, đây cũng là cặp giao dịch có khối lượng giao dịch lớn, giúp việc thu thập và xử lý dữ liệu trở nên thuận lợi hơn so với nhiều tài sản có thanh khoản thấp. Tuy nhiên, chính mức độ biến động mạnh và tính nhiễu cao của dữ liệu tài chính cũng làm cho việc dự báo giá trở nên khó khăn, đặc biệt nếu chỉ sử dụng các phương pháp truyền thống hoặc tiếp cận bài toán theo hướng quá đơn giản.

Từ thực tế đó, nghiên cứu này được thực hiện nhằm xây dựng một quy trình tương đối hoàn chỉnh cho bài toán giao dịch định lượng trên ETHUSDT, bao gồm các bước từ xử lý dữ liệu, xây dựng đặc trưng kỹ thuật, huấn luyện mô hình học máy đến chuyển đầu ra của mô hình thành tín hiệu giao dịch và đánh giá bằng backtest. Cách tiếp cận này phù hợp với định hướng ứng dụng của học phần, đồng thời cho phép đánh giá không chỉ hiệu quả dự báo mà còn cả giá trị kinh tế của mô hình.

2. Tổng quan nghiên cứu

Trong lĩnh vực tài chính định lượng, dự báo biến động giá và xây dựng chiến lược giao dịch là một chủ đề đã được nghiên cứu rộng rãi với nhiều hướng tiếp cận khác nhau. Một trong những hướng tiếp cận truyền thống là phân tích kỹ thuật, trong đó các chỉ báo như RSI, MACD, Bollinger Bands hay đường trung bình động được sử dụng để nhận diện xu hướng, động lượng và tín hiệu mua bán trên thị trường (Murphy, 1999). Ưu điểm của nhóm phương pháp này là trực quan, dễ triển khai và phù hợp với dữ liệu giá trong ngắn hạn. Tuy nhiên, hạn chế của chúng là phần lớn dựa trên các quy tắc cố định, do đó hiệu quả có thể suy giảm khi điều kiện thị trường thay đổi mạnh hoặc khi dữ liệu chứa nhiễu nhiều.

Cùng với sự phát triển của khoa học dữ liệu, học máy ngày càng được ứng dụng nhiều hơn trong nghiên cứu tài chính nhằm khai thác các quan hệ phi tuyến và cấu trúc phức tạp của dữ liệu (Tạp chí Kinh tế-Tài chính Online, 2021). Một số nghiên cứu thực nghiệm cho thấy các mô hình học máy có thể cải thiện khả năng dự báo so với các phương pháp truyền thống, đặc biệt khi

được kết hợp với hệ thống đặc trưng kỹ thuật phù hợp (Vũ et al., 2025). So với cách tiếp cận dựa hoàn toàn vào quy tắc kỹ thuật, học máy cho phép mô hình hóa đồng thời nhiều biến đầu vào, qua đó mở rộng khả năng nhận diện tín hiệu từ dữ liệu lịch sử.

Trong số các mô hình học máy hiện đại, XGBoost được đánh giá là một phương pháp nổi bật nhờ khả năng xử lý dữ liệu nhiễu, học các quan hệ phi tuyến và kiểm soát overfitting thông qua cơ chế regularization (Chen & Guestrin, 2016). Đây cũng là mô hình đã được sử dụng rộng rãi trong nhiều bài toán phân loại và dự báo nhờ hiệu quả thực nghiệm tốt, tốc độ huấn luyện cao và khả năng làm việc linh hoạt với tập đặc trưng có cấu trúc phức tạp.

Tuy nhiên, một điểm quan trọng được nhấn mạnh trong các nghiên cứu gần đây là chất lượng của mô hình dự báo không nên chỉ được đánh giá bằng các chỉ số thống kê như accuracy hay log-loss. Trong bối cảnh giao dịch tài chính, giá trị thực tiễn của mô hình chỉ thực sự được khẳng định khi đầu ra dự báo được chuyển hóa thành tín hiệu giao dịch cụ thể và được kiểm định thông qua backtest trên dữ liệu ngoài mẫu. Nói cách khác, mục tiêu cuối cùng không chỉ là dự báo đúng hướng giá, mà còn là xây dựng được một hệ thống giao dịch có khả năng tạo ra hiệu quả kinh tế sau khi đã xét đến logic vào/ra lệnh và quản trị rủi ro.

Từ góc độ đó, nghiên cứu này kế thừa các kết quả từ tài liệu trước theo ba hướng chính. Thứ nhất, nghiên cứu sử dụng các chỉ báo kỹ thuật phổ biến làm nền tảng cho bước xây dựng đặc trưng đầu vào. Thứ hai, nghiên cứu áp dụng mô hình học máy, trong đó XGBoost được lựa chọn làm mô hình chính, để kiểm tra khả năng khai thác tín hiệu từ dữ liệu ETHUSDT. Thứ ba, thay vì dừng lại ở bước dự báo, nghiên cứu tiếp tục chuyển xác suất dự báo thành tín hiệu giao dịch và đánh giá bằng các chỉ tiêu tài chính như Total Return, CAGR, Sharpe Ratio và Maximum Drawdown. Cách tiếp cận này giúp đề tài gắn chặt hơn với mục tiêu ứng dụng của khoa học dữ liệu trong kinh tế và kinh doanh.

3. Mục tiêu nghiên cứu

Nghiên cứu được thực hiện với ba mục tiêu chính. Mục tiêu thứ nhất là mô tả và xử lý bộ dữ liệu ETHUSDT khung 30 phút theo đúng đặc trưng của dữ liệu chuỗi thời gian tài chính, từ đó tạo ra tập dữ liệu đầu vào phù hợp cho phân tích và mô hình hóa.

Mục tiêu thứ hai là xây dựng hệ thống đặc trưng kỹ thuật có khả năng phản ánh các khía cạnh quan trọng của thị trường như động lượng, xu hướng, biến động và thanh khoản, đồng thời đánh giá mức độ phù hợp của các đặc trưng này đối với bài toán dự báo hướng giá ngắn hạn.

Mục tiêu thứ ba là xây dựng và kiểm thử một chiến lược giao dịch dựa trên đầu ra của mô hình học máy. Ở đây, nghiên cứu không chỉ dừng lại ở việc so sánh các mô hình bằng chỉ số thống kê, mà còn tập trung đánh giá hiệu quả kinh tế của chiến lược thông qua các chỉ tiêu như Total Return, CAGR, Sharpe Ratio, Maximum Drawdown và Win Rate. Thông qua đó, nghiên cứu hướng đến việc trả lời liệu một hệ thống giao dịch kết hợp giữa học máy và quản trị rủi ro có thể tạo ra kết quả tốt hơn so với chiến lược nắm giữ thụ động hay không.

4. Câu hỏi nghiên cứu

Từ các mục tiêu trên, nghiên cứu tập trung trả lời một số câu hỏi chính. Thứ nhất, dữ liệu ETHUSDT ở tần suất 30 phút có những đặc điểm thống kê nào nổi bật và vì sao không nên sử dụng trực tiếp mức giá đóng cửa làm đầu vào cho mô hình. Thứ hai, những đặc trưng kỹ thuật nào là phù hợp để mô tả trạng thái thị trường và hỗ trợ bài toán dự báo xu hướng giá trong ngắn hạn.

Thứ ba, mô hình phi tuyến như XGBoost có cải thiện được hiệu quả dự báo so với mô hình tuyến tính cơ sở như Logistic Regression hay không. Thứ tư, khi đầu ra xác suất của mô hình được chuyển hóa thành tín hiệu giao dịch và kết hợp với cơ chế quản trị rủi ro, chiến lược tạo ra có đạt hiệu quả tốt hơn so với chiến lược Buy and Hold trên cùng giai đoạn dữ liệu hay không. Việc trả lời những câu hỏi này sẽ giúp làm rõ cả khía cạnh phương pháp lẫn giá trị ứng dụng của đề tài.

5. Đối tượng, phạm vi và đóng góp của nghiên cứu

Đối tượng nghiên cứu của đề tài là chiến lược giao dịch định lượng theo hướng long/flat trên cặp ETHUSDT. Dữ liệu được sử dụng là dữ liệu nến 30 phút trong giai đoạn từ cuối năm 2019 đến giữa năm 2025, bao gồm các biến cơ bản thuộc nhóm OHLCV. Phạm vi nghiên cứu tập trung vào việc khai thác thông tin từ dữ liệu giá và khối lượng giao dịch để xây dựng đặc trưng kỹ thuật, huấn luyện mô hình dự báo và thiết kế chiến lược giao dịch phù hợp với dữ liệu ngoài mẫu.

Đóng góp của nghiên cứu thể hiện ở ba khía cạnh. Thứ nhất, đề tài xây dựng được một quy trình xử lý và phân tích dữ liệu tương đối đầy đủ cho bài toán giao dịch tài chính ngắn hạn. Thứ hai, nghiên cứu kết hợp được nội dung của nhiều phần trong học phần, bao gồm xử lý dữ liệu, trực quan hóa, học máy có giám sát và đánh giá hiệu quả bằng các chỉ tiêu tài chính. Thứ ba, đề tài không chỉ dừng ở việc xây dựng mô hình dự báo mà còn chuyển hóa đầu ra của mô hình thành chiến lược giao dịch cụ thể, từ đó đánh giá được giá trị kinh tế thực sự của hệ thống được đề xuất.

II. DỮ LIỆU VÀ TIỀN XỬ LÝ

1. Mô tả dữ liệu nghiên cứu

1.1. Cấu trúc bộ dữ liệu

Bộ dữ liệu sử dụng trong nghiên cứu là dữ liệu giá lịch sử của cặp giao dịch ETHUSDT ở khung thời gian 30 phút, được thu thập từ sàn giao dịch Binance. Dữ liệu gốc bao 100.222 quan sát và 6 biến theo cấu trúc OHLCV chuẩn trong phân tích tài chính định lượng, trong đó timestamp ghi nhận mốc thời gian của từng nến 30 phút; open, high, low và close lần lượt biểu thị giá mở cửa, giá cao nhất, giá thấp nhất và giá đóng cửa trong khoảng thời gian tương ứng; volume phản ánh tổng khối lượng giao dịch phát sinh trong nến đó. Bảng 2.1 mô tả chi tiết ý nghĩa của từng biến trong bộ dữ liệu gốc.

Bảng 2.1. Mô tả các biến trong bộ dữ liệu gốc

Biến	Ý nghĩa
timestamp	Mốc thời gian của mỗi nến 30 phút (datetime index)
open	Giá mở cửa trong phiên nến
high	Giá cao nhất trong phiên nến
low	Giá thấp nhất trong phiên nến
close	Giá đóng cửa - biến nền tảng cho mọi tính toán chỉ báo và biến mục tiêu
volume	Khối lượng giao dịch phát sinh trong phiên nến

1.2. Quy mô và phạm vi thời gian của dữ liệu

Bộ dữ liệu bao phủ giai đoạn từ ngày 27/11/2019 đến ngày 15/08/2025, với tổng cộng 100.222 quan sát và không có giá trị thiếu trên bất kỳ biến nào. Đây là một phạm vi thời gian đủ dài để phản ánh nhiều trạng thái thị trường khác biệt nhau, bao gồm giai đoạn tăng trưởng mạnh, điều chỉnh sâu, đi ngang kéo dài và hồi phục. Tính đa dạng về trạng thái thị trường là điều kiện quan trọng để đánh giá xem chiến lược có khả năng thích nghi với nhiều môi trường giao dịch khác nhau hay chỉ phù hợp với một trạng thái cụ thể. Bảng 2.2 trình bày tóm tắt các thông số cơ bản của bộ dữ liệu.

Bảng 2.2. Thông số cơ bản của bộ dữ liệu gốc

Chỉ tiêu	Giá trị
Số dòng dữ liệu gốc	100.222
Số cột dữ liệu gốc	6
Thời gian bắt đầu	2019-11-27 07:30:00
Thời gian kết thúc	2025-08-15 06:00:00

Tổng số giá trị thiếu	0
Số dòng volume = 0 trước xử lý	5

2. Quy trình tiền xử lý dữ liệu

Quy trình tiền xử lý được thực hiện tuần tự theo đúng logic của dữ liệu chuỗi thời gian. Trước hết, cột thời gian được chuyển sang định dạng datetime để đảm bảo khả năng sắp xếp và trích xuất thông tin theo giờ, ngày hoặc chu kỳ. Tiếp theo, dữ liệu được sắp xếp tăng dần theo thời gian và lấy timestamp làm chỉ mục. Sau đó, các giá trị volume bằng 0 được thay bằng 0,0001. Cuối cùng, nghiên cứu tạo thêm biến log-return nhằm phục vụ phân phân tích khám phá dữ liệu và kiểm tra phân phối. Bảng 2.3 tóm tắt toàn bộ quy trình này.

Bảng 2.3. Các bước tiền xử lý dữ liệu

Bước	Thao tác	Mục đích
1	Chuyển định dạng timestamp	Đảm bảo cột thời gian được nhận diện đúng kiểu datetime, tạo điều kiện sắp xếp và trích xuất thông tin theo giờ, ngày,
2	Đặt timestamp làm chỉ mục, sắp xếp tăng dần	Đảm bảo tính liên mạch của chuỗi thời gian, tránh đảo lộn thứ tự gây sai lệch tính toán chỉ báo
3	Thay volume = 0 bằng 0,0001	Tránh lỗi chia cho 0 khi tính Vol_Ratio và tránh vô cực âm khi lấy logarit; giữ nguyên ý nghĩa “gần như bằng 0”
4	Resample tần suất 30 phút (ffill)	Điền các khoảng trống thời gian bằng giá trị liên trước, duy trì cấu trúc liên tục cho rolling window
5	Tính log-return (Log_Ret)	Phục vụ phân tích phân phối, kiểm định Jarque-Bera và xây dựng biến Returns cho mô hình
6	Xây dựng feature engineering và loại bỏ dòng NaN	Tạo tập đặc trưng kỹ thuật; loại bỏ 21 dòng đầu phát sinh bởi rolling window và lag features chưa đủ dữ liệu

2.1. Chuyển đổi định dạng thời gian và thiết lập chỉ mục

Cột timestamp ban đầu được lưu dưới dạng chuỗi ký tự (string). Bước đầu tiên là chuyển sang kiểu datetime của pandas để đảm bảo khả năng sắp xếp theo thứ tự thời gian, trích xuất thông tin giờ/ngày/tuần phục vụ xây dựng biến chu kỳ, và kích hoạt các hàm rolling, resample của thư viện. Sau khi chuyển đổi, timestamp được đặt làm chỉ mục (index) và dữ liệu được sắp xếp tăng dần từ quá khứ đến hiện tại:

```
df['timestamp'] = pd.to_datetime(df['timestamp'])
df.set_index('timestamp', inplace=True)
df.sort_index(inplace=True)
```

2.2. Xử lý giá trị volume bằng 0

Phát hiện 5 dòng có volume bằng 0 trong quá trình khám phá dữ liệu ban đầu. Dù không phải lỗi dữ liệu nghiêm trọng, các dòng này gây ra ba nguy cơ tiềm ẩn nếu không được xử lý:

- Lỗi chia cho 0 khi tính chỉ báo Vol_Ratio = Volume / MA(Volume, 20).
- Kết quả vô cực âm ($-\infty$) nếu áp dụng phép biến đổi logarit lên volume.
- Nhiễu trong quá trình học của mô hình ML do giá trị bất thường cực đoan.

Giải pháp được chọn là thay thế các giá trị bằng 0 bằng $\varepsilon = 0,0001$. Cách tiếp cận này giữ nguyên ý nghĩa thực tế rằng khối lượng giao dịch gần như bằng không, trong khi vẫn cho phép thực hiện các phép tính số học một cách an toàn:

```
df['volume'] = df['volume'].replace(0, 0.0001)
```

2.3. Đảm bảo tính liên tục chuỗi thời gian (Resample)

Thị trường tiền mã hóa hoạt động liên tục 24/7, nhưng trên thực tế vẫn có thể xuất hiện những khoảng trống nhỏ trong dữ liệu do lỗi thu thập hoặc gián đoạn kết nối. Để đảm bảo chuỗi thời gian 30 phút là hoàn toàn liên tục - điều kiện bắt buộc để các chỉ báo rolling window hoạt động đúng - dữ liệu được resample về tần suất cố định 30 phút và điền các khoảng trống bằng phương pháp forward fill (ffill):

```
df = df.asfreq('30min', method='ffill')
```

Phương pháp ffill nghĩa là nếu một nến 30 phút bị thiếu, toàn bộ giá trị của nó được sao chép từ nến liền trước. Đây là cách xử lý phù hợp với đặc điểm thị trường crypto nơi giá không dịch chuyển khi không có giao dịch, tốt hơn so với các phương pháp nội suy tuyến tính có thể tạo ra các giá trị ảo.

2.4. Tính log-return và ý nghĩa trong phân tích tài chính

Biến log-return được tính theo công thức chuẩn trong tài chính định lượng:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$$

trong đó P_t là giá đóng cửa tại thời điểm t. So với mức giá tuyệt đối, log-return có ba ưu điểm cốt lõi: (i) phản ánh tốc độ thay đổi tương đối của giá thay vì mức tuyệt đối; (ii) có tính chất cộng theo thời gian, giúp tính lợi suất tích lũy dễ dàng hơn; và (iii) ổn định hơn về mặt thống kê - đặc biệt quan trọng khi xây dựng đặc trưng đầu vào cho mô hình ML.


```
df['Log_Ret'] = np.log(df['close'] / df['close'].shift(1))
```

Sau khi tính log-return, nghiên cứu thực hiện kiểm định Jarque-Bera (JB) để kiểm tra liệu chuỗi lợi suất có tuân theo phân phối chuẩn hay không. Kiểm định JB sử dụng hai tham số là độ lệch (skewness) và độ nhọn (kurtosis) để xây dựng thống kê kiểm định:

$$JB = \frac{n}{6} \left[S^2 + \frac{(K - 3)^2}{4} \right]$$

trong đó S là độ lệch và K là độ nhọn của chuỗi. Giả thuyết không (H_0) là chuỗi có phân phối chuẩn ($S = 0, K = 3$).

Hình 2.1 so sánh histogram dữ liệu thực tế với đường chuẩn lý thuyết trên thang log, cho thấy rõ hiện tượng fat tails - xác suất xuất hiện các biến động cực đoan (tăng/giảm mạnh đột ngột) lớn hơn đáng kể so với giả định Gaussian. Đây là bằng chứng trực quan xác nhận kết quả kiểm định thống kê và là lý do tại sao không nên sử dụng các mô hình dựa trên giả định phân phối chuẩn cho dữ liệu tài chính này.



Hình 2.1. Minh chứng "Fat_tails": Dữ liệu thực tế vượt xa hơn Phân phối chuẩn

2.5. Kiểm định tính dừng của chuỗi

Sau khi tính log-return và xây dựng các biến biến đổi ban đầu, nghiên cứu tiếp tục sử dụng kiểm định Augmented Dickey-Fuller (ADF) để đánh giá tính dừng của chuỗi giá gốc và các biến đầu vào chính. Bước này nhằm kiểm tra liệu các biến sau biến đổi có phù hợp hơn về mặt thống kê so với chuỗi giá đóng cửa hay không.

Giả thuyết không H_0 của kiểm định ADF cho rằng chuỗi có nghiệm đơn vị, tức là không dừng. Nếu p-value nhỏ hơn mức ý nghĩa lựa chọn, có thể bác bỏ H_0 và kết luận chuỗi có đặc


điểm dừng tốt hơn. Trong nghiên cứu này, kiểm định ADF được sử dụng như một công cụ hỗ trợ cho việc sàng lọc đặc trưng, còn kết quả chi tiết được trình bày ở phần Kết quả nghiên cứu.

3. Trục quan hóa dữ liệu

Trước khi tiến hành tiền xử lý và xây dựng mô hình, nghiên cứu thực hiện trục quan hóa dữ liệu nhằm nhận diện sơ bộ đặc điểm biến động của giá và lợi suất. Ba biểu đồ được sử dụng trong bước này bao gồm: diễn biến giá và khối lượng theo thời gian, diễn biến log-return theo thời gian và phân phối của log-return.

3.1. Diễn biến giá và khối lượng giao dịch theo thời gian

Biểu đồ dưới đây mô tả đồng thời diễn biến giá đóng cửa của ETHUSDT và khối lượng giao dịch trong toàn bộ giai đoạn nghiên cứu. Đây là bước trục quan hóa đầu tiên nhằm quan sát các giai đoạn tăng trưởng, điều chỉnh và phục hồi của thị trường, cũng như sự thay đổi về cường độ giao dịch theo thời gian.




Hình 2.2. Diễn biến giá ETHUSDT và khối lượng giao dịch theo thời gian

Từ biểu đồ có thể thấy giá ETHUSDT biến động rất mạnh qua các năm, với những giai đoạn tăng nhanh, giảm sâu rồi phục hồi rõ rệt. Khối lượng giao dịch cũng dao động đáng kể và thường tăng lên trong các giai đoạn thị trường biến động mạnh. Điều này cho thấy chuỗi giá mang đặc trưng phi tuyến, nhiễu nhiều và thay đổi đáng kể theo từng trạng thái thị trường.

3.2. Diễn biến lợi suất logarit theo thời gian

Để giảm ảnh hưởng của xu hướng giá dài hạn, nghiên cứu chuyển chuỗi giá đóng cửa sang chuỗi lợi suất logarit (log-return) và quan sát diễn biến của chuỗi này theo thời gian. Biểu đồ sau cho thấy mức biến động ngắn hạn của lợi suất quanh giá trị trung tâm.




Hình 2.3. Diễn biến lợi suất logarit theo thời gian

Chuỗi log-return dao động quanh mức 0 thay vì mang xu hướng tăng dài hạn như chuỗi giá gốc. Tuy nhiên, biên độ dao động không đồng đều giữa các giai đoạn và có hiện tượng các giai đoạn biến động lớn xuất hiện thành cụm. Đây là dấu hiệu cho thấy dữ liệu tài chính ngắn hạn có đặc điểm volatility clustering, tức là biến động mạnh thường đi kèm với biến động mạnh.

3.3. Phân phối của log-return

Bên cạnh việc quan sát theo trục thời gian, nghiên cứu tiếp tục kiểm tra hình dạng phân phối của log-return nhằm đánh giá sơ bộ đặc điểm rủi ro của dữ liệu. Histogram kết hợp đường mật độ dưới đây cho thấy hình dạng phân phối của chuỗi lợi suất.



Hình 2.4. Phân phối của lợi suất logarit

Phân phối của log-return tập trung mạnh quanh giá trị 0 nhưng phần đuôi vẫn kéo dài đáng kể về hai phía. Điều này cho thấy lợi suất của ETHUSDT không tuân theo dạng chuẩn lý tưởng mà có xu hướng đuôi dày (fat tails), tức xác suất xuất hiện các biến động cực đoan lớn hơn so với phân

phối chuẩn. Kết quả trực quan hóa này là cơ sở quan trọng để nghiên cứu tiếp tục thực hiện các bước tiền xử lý và xây dựng đặc trưng kỹ thuật phù hợp hơn cho mô hình học máy.

4. Tập dữ liệu sau xử lý

Sau khi hoàn tất các bước làm sạch cơ bản, tính log-return và xây dựng các đặc trưng kỹ thuật, tập dữ liệu dùng cho mô hình còn 100.201 quan sát. So với 100.222 dòng của bộ dữ liệu ban đầu, số lượng quan sát bị loại bỏ là 21 dòng; phần giảm này chủ yếu phát sinh từ rolling window và các biến trễ. Đồng thời, số biến sau xử lý tăng lên 27 cột, bao gồm nhóm biến giá, khối lượng, biến mục tiêu và toàn bộ các đặc trưng kỹ thuật.

III. PHƯƠNG PHÁP NGHIÊN CỨU

1. Quy trình nghiên cứu tổng quát

Phương pháp nghiên cứu được xây dựng theo chuỗi các bước liên kết chặt chẽ và mạch lạc, dựa trên nền tảng của Machine Learning. Quy trình bắt đầu bằng việc tiền xử lý dữ liệu và phân tích thống kê mô tả. Tiếp theo là xây dựng tập feature kỹ thuật từ dữ liệu OHLCV. Sau đó, các feature được sàng lọc bằng kiểm định tính dừng và phân tích tương quan. Trên tập dữ liệu đã chuẩn bị, nghiên cứu thiết lập biến mục tiêu, chia train-test theo thời gian đồng thời tránh rò rỉ thông tin và huấn luyện hai mô hình: Logistic Regression và XGBoost. Cuối cùng, đầu ra xác suất của mô hình chính được chuyển hóa thành chiến lược giao dịch, backtest trên tập kiểm tra và đánh giá bằng các chỉ tiêu tài chính.

2. Xây dựng đặc trưng kỹ thuật

Feature engineering là phần trung tâm của nghiên cứu. Mục tiêu của bước này là chuyển hoá các dữ liệu giá thô không có tính dừng thành những đại lượng có nội dung kinh tế rõ ràng hơn và ổn định hơn về mặt thống kê. Các feature được xây dựng có thể chia thành bốn nhóm chính: nhóm động lượng, nhóm xu hướng, nhóm biến động và nhóm thanh khoản; bên cạnh đó là các biến trễ và biến thời gian chu kỳ.

2.1. Nhóm động lượng

2.1.1. Returns

Returns là lợi suất logarit giữa hai phiên giao dịch liên tiếp. Đây là feature cơ sở phản ánh hướng và cường độ thay đổi giá trong ngắn hạn. Đặc trưng này có tính dừng tốt hơn so với giá, phù hợp hơn cho các mô hình Machine Learning. Feature giúp mô hình nhận diện xu hướng tăng giảm cục bộ giữa các nền.

$$Return_t = \log\left(\frac{Close_t}{Close_{t-1}}\right)$$

2.1.2. RSI (Relative Strength Index)

RSI là chỉ báo động lượng, dao động trong khoảng 0-100, đo lường tốc độ và cường độ thay đổi giá.

RSI được tính trên cửa sổ 14 kỳ và phản ánh trạng thái quá mua hoặc quá bán của thị trường. Khi RSI ở mức thấp, thị trường thường bị bán quá mức; khi RSI ở mức cao, thị trường có thể rơi vào trạng thái quá mua. Trong nghiên cứu này, RSI giúp mô hình bổ sung một tín hiệu phi tuyến bên cạnh returns.

Lựa chọn chu kỳ 14 phiên vì đây là tiêu chuẩn phổ biến trong phân tích kỹ thuật: đủ ngắn để phản ứng nhanh nhưng vẫn đủ dài để giảm nhiễu.

$$RSI = 100 - \frac{100}{1 + RS}$$
$$RS = \frac{\text{Mức tăng trung bình}}{\text{Mức giảm trung bình}}$$

2.2. Nhóm xu hướng

2.2.1. PPO (Percentage Price Oscillator)

PPO là tỷ lệ phần trăm chênh lệch giữa EMA ngắn hạn và EMA dài hạn. Feature này cho biết xu hướng ngắn hạn đang mạnh hơn hay yếu hơn xu hướng trung hạn.

$$PPO = \frac{EMA_{12} - EMA_{26}}{EMA_{26}} \cdot 100$$

Trong đó: EMA (Exponential Moving Average) là trung bình động có trọng số lớn hơn cho dữ liệu gần hiện tại.

$$EMA_t = (Giá_t - EMA_{t-1}) \cdot K + EMA_{t-1}$$

2.2.2. PPO_Hist

PPO_Hist được tính bằng PPO trừ đi đường tín hiệu của chính PPO. Có thể xem đây là một dạng gia tốc của xu hướng. Khi PPO_Hist tăng, xu hướng đang được củng cố; khi giảm, động lượng xu hướng suy yếu. Rất hữu ích cho mô hình phi tuyến (XGBoost) trong việc phát hiện điểm đảo chiều sớm.

$$PPO_{Hist} = PPO - PPO_{Signal}$$

2.3. Nhóm biến động và vị trí giá

2.3.1. BB_PctB (%B – Bollinger Band)

BB_PctB đo vị trí tương đối của giá trong dải Bollinger. Feature này rất hữu ích vì nó cho phép mô hình biết giá hiện tại đang nằm gần biên trên, biên dưới hay quanh trung bình động ngắn hạn. Cung cấp thông tin về vị trí tương đối của giá, độc lập với mức giá tuyệt đối.

$$\%B = \frac{Close - LowerBand}{UpperBand - LowerBand}$$

2.3.2. *ATR_Pct (Average True Range Percentage)*

ATR_Pct là Average True Range chuẩn hóa theo mức giá. Nếu ATR_Pct cao, thị trường đang biến động mạnh; nếu thấp, thị trường có xu hướng đi ngang hoặc biến động yếu. Giúp mô hình điều chỉnh kỳ vọng lợi nhuận theo trạng thái biến động của thị trường.

2.4. Nhóm thanh khoản và cấu trúc thời gian

2.4.1. *Vol_Ratio*

Vol_Ratio lấy khối lượng hiện tại chia cho khối lượng trung bình 20 kỳ. Đây là cách đánh giá xem dòng tiền hiện tại có mạnh hơn mức thông thường hay không. Xác nhận độ tin cậy của tín hiệu giá.

$$Vol_{Ratio} = \frac{Volume_t}{MA_{20}(Volume)}$$

2.4.2. *Hour_Sin và Hour_Cos*

Với dữ liệu 30 phút trên thị trường crypto hoạt động liên tục, biến thời gian trong ngày có thể tác động đến thanh khoản và biến động. Nghiên cứu mã hóa giờ theo hàm sin và cos để giữ được tính chu kỳ của thời gian, giúp máy tránh hiểu sai 23h và 0h cách xa nhau.

$$hour_{sin} = \sin\left(2\pi \cdot \frac{hour}{24}\right)$$

$$hour_{cos} = \cos\left(2\pi \cdot \frac{hour}{24}\right)$$

2.5. Các biến trễ

Ngoài giá trị hiện tại, nghiên cứu bổ sung Returns_Lag1, RSI_Lag1, PPO_Hist_Lag1 và các độ trễ tương tự. Các biến này cho phép mô hình nắm bắt tính phụ thuộc theo thời gian, vốn là đặc trưng tự nhiên của chuỗi tài chính. Cho phép mô hình tái hiện logic của AR/MA nhưng theo cách phi tuyến.

3. Kiểm định tính dừng và sàng lọc feature

Sau khi xây dựng các đặc trưng kỹ thuật từ dữ liệu OHLCV, nghiên cứu tiến hành kiểm tra tính dừng của một số biến đầu vào bằng kiểm định Augmented Dickey–Fuller (ADF). Bước này nhằm đánh giá xem các chuỗi sử dụng cho mô hình có phù hợp hơn về mặt thống kê so với chuỗi giá gốc hay không. Trong dữ liệu tài chính, giá đóng cửa thường mang tính không dừng, trong khi các đặc trưng đã biến đổi như lợi suất, chỉ báo động lượng hoặc biến động thường ổn định hơn và phù hợp hơn cho mô hình hóa.

Kết quả kiểm định cho thấy chuỗi giá đóng cửa thô không đáp ứng tốt điều kiện dừng, trong khi phần lớn các đặc trưng kỹ thuật sau biến đổi có đặc điểm thống kê phù hợp hơn. Điều này củng cố lựa chọn sử dụng feature engineering thay vì đưa trực tiếp mức giá vào mô hình.

Bên cạnh đó, nghiên cứu cũng thực hiện sàng lọc đặc trưng nhằm giảm hiện tượng trùng lặp thông tin giữa các biến đầu vào. Các biến có tương quan tuyến tính quá cao được xem xét loại bỏ để hạn chế đa cộng tuyến trong mô hình tuyến tính và giúp tập đặc trưng trở nên gọn hơn, dễ diễn giải hơn.

4. Xây dựng biến mục tiêu

Trên cơ sở tập đặc trưng đã xây dựng, nghiên cứu thiết lập biến mục tiêu dưới dạng nhị phân để phục vụ bài toán phân loại. Cụ thể, mục tiêu của mô hình là dự báo hướng biến động giá ở kỳ tiếp theo, thay vì dự báo trực tiếp mức giá tuyệt đối. Biến mục tiêu được xác định như sau:

$$Target_t = \begin{cases} 1, & \text{nếu } Close_{t+1} > Close_t \\ 0, & \text{nếu } Close_{t+1} < Close_t \end{cases}$$

Cách thiết kế này phù hợp với mục tiêu giao dịch ngắn hạn, vì trong thực tế ra quyết định, điều quan trọng hơn là dự báo được xu hướng tăng hay giảm của giá trong kỳ kế tiếp. Đồng thời, việc chuyển bài toán sang dạng phân loại cũng tạo điều kiện thuận lợi cho việc áp dụng các mô hình như Logistic Regression và XGBoost ở phần sau. Ngoài ra, do đầu ra của mô hình có thể được biểu diễn dưới dạng xác suất, biến mục tiêu nhị phân còn giúp kết nối trực tiếp giữa bước mô hình hóa và bước thiết kế tín hiệu giao dịch trong nghiên cứu.

5. Chiến lược chia train–test theo thời gian

Do dữ liệu nghiên cứu là dữ liệu chuỗi thời gian, việc chia tập huấn luyện và tập kiểm tra được thực hiện theo đúng thứ tự thời gian thay vì chia ngẫu nhiên. Cách làm này nhằm bảo đảm rằng mô hình chỉ được học từ dữ liệu quá khứ và được đánh giá trên dữ liệu xảy ra sau đó, phù hợp với bản chất của bài toán dự báo tài chính.

Trong nghiên cứu này, tập huấn luyện chiếm khoảng 70% số quan sát đầu tiên, còn tập kiểm tra được lấy từ phần dữ liệu tiếp theo. Đồng thời, giữa hai tập dữ liệu có chèn một khoảng đệm nhỏ (embargo) để hạn chế nguy cơ rò rỉ thông tin tại vùng tiếp giáp, đặc biệt trong bối cảnh các đặc trưng được xây dựng từ rolling window và biến trễ.

Chiến lược chia train–test theo thời gian giúp kết quả đánh giá phản ánh sát hơn khả năng hoạt động của mô hình trên dữ liệu ngoài mẫu. Đây là một yêu cầu quan trọng trong nghiên cứu tài chính, vì một mô hình chỉ có ý nghĩa khi tín hiệu học được từ quá khứ vẫn còn giá trị đối với giai đoạn tương lai.

6. Mô hình nghiên cứu

6.1. Logistic Regression

Logistic Regression được lựa chọn làm mô hình baseline trong nghiên cứu này. Việc sử dụng mô hình này có hai ý nghĩa chính. Thứ nhất, đây là một mô hình phân loại tuyến tính cơ bản, dễ diễn giải và được sử dụng phổ biến trong các bài toán dự báo nhị phân. Thứ hai, nếu Logistic Regression đã cho kết quả tốt hơn mức ngẫu nhiên, điều đó cho thấy tập đặc trưng được xây dựng từ dữ liệu giá có chứa thông tin dự báo nhất định. Trên cơ sở đó, việc so sánh với mô hình phi tuyến như XGBoost sẽ giúp đánh giá rõ hơn giá trị gia tăng của các phương pháp học máy phức tạp hơn.

Về mặt lý thuyết, Logistic Regression mô hình hóa xác suất xảy ra của biến mục tiêu thông qua hàm sigmoid. Trong nghiên cứu này, biến mục tiêu được định nghĩa dưới dạng nhị phân, với $Y = 1$ nếu giá đóng cửa ở thời điểm kế tiếp tăng so với thời điểm hiện tại và $Y = 0$ trong trường hợp ngược lại. Với vector đặc trưng đầu vào $\mathbf{x} = (x_1, x_2, \dots, x_k)$, mô hình ước lượng xác suất:

$$P(Y = 1 | \mathbf{x}) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

trong đó:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k$$

Ở đây, β_0 là hệ số chặn, còn $\beta_1, \beta_2, \dots, \beta_k$ là các hệ số gắn với các biến đầu vào. Hàm sigmoid có vai trò biến đổi tổ hợp tuyến tính z thành một giá trị xác suất nằm trong khoảng từ 0 đến 1, nhờ đó phù hợp với bài toán phân loại nhị phân.

Các tham số của mô hình được ước lượng bằng cách cực đại hóa hàm hợp lý, hay tương đương là tối thiểu hóa hàm mất mát log-loss (binary cross-entropy). Hàm log-likelihood của Logistic Regression có thể viết dưới dạng:

$$\ell(\beta) = \sum_{i=1}^n [y_i \log(P_i) + (1 - y_i) \log(1 - P_i)]$$

trong đó $y_i \in \{0, 1\}$ là nhãn thực tế của quan sát thứ i , còn $P_i = P(Y = 1 | x_i)$ là xác suất dự báo tương ứng từ mô hình. Cách tiếp cận này cho phép mô hình không chỉ đưa ra nhãn dự báo mà còn lượng hóa mức độ tin cậy của từng dự báo thông qua xác suất.

Tuy nhiên, trước khi đưa dữ liệu vào Logistic Regression, nghiên cứu thực hiện hai bước tiền xử lý quan trọng nhằm đảm bảo tính ổn định của ước lượng. Thứ nhất, các biến đầu vào được chuẩn hóa bằng StandardScaler để đưa về cùng thang đo. Với một đặc trưng x , phép chuẩn hóa được thực hiện theo công thức:

$$x^* = \frac{x - \mu}{\sigma}$$

trong đó μ là giá trị trung bình và σ là độ lệch chuẩn của biến trên tập huấn luyện. Việc chuẩn hóa là cần thiết vì Logistic Regression là mô hình tuyến tính khá nhạy với sự khác biệt về đơn vị đo lường giữa các biến. Nếu các đặc trưng có thang đo quá khác nhau, quá trình ước lượng hệ số có thể trở nên kém ổn định và khó diễn giải.

Thứ hai, nghiên cứu tiến hành loại bỏ các biến có tương quan tuyến tính quá cao nhằm giảm hiện tượng đa cộng tuyến. Trong trường hợp các biến đầu vào mang thông tin gần như trùng lặp, hệ số ước lượng của Logistic Regression có thể trở nên không ổn định, từ đó làm giảm khả năng diễn giải của mô hình và ảnh hưởng đến hiệu quả dự báo ngoài mẫu.

Từ góc độ phương pháp, Logistic Regression có ưu điểm là đơn giản, dễ triển khai và giúp kiểm tra nhanh xem các đặc trưng kỹ thuật có mang tín hiệu dự báo tuyến tính hay không. Tuy nhiên, dữ liệu tài chính thường có tính phi tuyến, nhiễu nhiễu và quan hệ giữa các biến không ổn định theo thời gian. Do đó, mô hình này chủ yếu đóng vai trò đường chuẩn để so sánh với các mô hình mạnh hơn về khả năng khai thác cấu trúc phi tuyến. Nói cách khác, mục tiêu của việc sử dụng Logistic Regression trong nghiên cứu không phải là tối ưu hóa trực tiếp hiệu quả giao dịch, mà là tạo ra một mốc tham chiếu hợp lý trước khi chuyển sang đánh giá mô hình XGBoost ở phần tiếp theo.

6.2. XGBoost

Bên cạnh các mô hình cơ bản đã được tiếp cận trong học phân, nghiên cứu này bổ sung thử nghiệm mô hình XGBoost như một hướng mở rộng nhằm kiểm tra khả năng cải thiện hiệu quả dự báo trên dữ liệu tài chính. Việc đưa thêm XGBoost vào nghiên cứu không nhằm thay thế vai trò của các mô hình đã học trên lớp, mà nhằm mở rộng phạm vi phân tích và đối chiếu kết quả giữa mô hình tuyến tính cơ sở với một mô hình học máy hiện đại có khả năng xử lý quan hệ phi tuyến.

XGBoost (Extreme Gradient Boosting) là một phương pháp thuộc nhóm mô hình dựa trên cây quyết định, cụ thể là Gradient Boosting Decision Trees. Khác với Decision Tree đơn lẻ hoặc Random Forest – vốn cũng là các mô hình dựa trên cây đã được giới thiệu (Đại học Kinh tế Quốc dân, n.d.) – XGBoost xây dựng các cây theo cơ chế tuần tự, trong đó mỗi cây mới được tạo ra để hiệu chỉnh sai số còn lại của các cây trước đó. Nhờ vậy, mô hình có khả năng học dần các mẫu phức tạp hơn trong dữ liệu.

Về mặt phương pháp, XGBoost tối ưu hóa một hàm mục tiêu gồm hai thành phần: hàm mất mát đo lường sai số dự báo và thành phần regularization kiểm soát độ phức tạp của mô hình. Dạng tổng quát của hàm mục tiêu được viết như sau:

$$\mathcal{L} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

trong đó $l(y_i, \hat{y}_i)$ là hàm mất mát của quan sát thứ i , còn $\Omega(f_k)$ là thành phần regularization áp dụng cho cây thứ k . Việc bổ sung regularization giúp XGBoost hạn chế hiện tượng overfitting, vốn là vấn đề khá phổ biến khi làm việc với dữ liệu tài chính có độ nhiễu cao.

Trong nghiên cứu này, XGBoost được sử dụng cho bài toán phân loại nhị phân, với mục tiêu dự báo hướng biến động giá trong kỳ tiếp theo. Mô hình học từ cùng một tập đặc trưng kỹ thuật đã xây dựng ở các bước trước, bao gồm các biến phản ánh động lượng, xu hướng, biến động và thanh khoản của thị trường. So với Logistic Regression, ưu điểm của XGBoost là không giả định mối quan hệ tuyến tính giữa các biến đầu vào và biến mục tiêu, đồng thời có khả năng nắm bắt tốt hơn các tương tác giữa các đặc trưng.

Nghiên cứu này tiếp cận mô hình theo hướng thận trọng. Cụ thể là XGBoost được sử dụng như một mô hình mở rộng để so sánh với baseline, thay vì xem như lựa chọn mặc định. Việc đánh giá mô hình không chỉ dựa trên accuracy hay log-loss, mà còn được đặt trong bối cảnh bài toán giao dịch thực tế, tức là đầu ra của mô hình phải được chuyển hóa thành tín hiệu giao dịch và kiểm định bằng backtest. Cách tiếp cận này giúp bảo đảm rằng việc bổ sung XGBoost có ý nghĩa phương pháp rõ ràng, đồng thời vẫn giữ được sự gắn kết với nội dung cốt lõi của học phân.

Kết quả thu được từ XGBoost vì vậy được hiểu như một bằng chứng bổ sung cho thấy khi chuyển từ mô hình tuyến tính cơ bản sang một mô hình phi tuyến mạnh hơn, chất lượng tín hiệu dự báo có thể được cải thiện ở một mức độ nhất định. Tuy nhiên, giá trị thực tiễn của sự cải thiện này chỉ được khẳng định khi xem xét đồng thời hiệu quả giao dịch và mức độ rủi ro của chiến lược trong phần backtest.

7. Chỉ tiêu đánh giá mô hình

Để đánh giá chất lượng mô hình phân loại, nghiên cứu sử dụng kết hợp nhiều chỉ tiêu thay vì chỉ dựa vào một thước đo duy nhất. Điều này là cần thiết vì trong bài toán dự báo xu hướng giá, mỗi chỉ số phản ánh một khía cạnh khác nhau của mô hình. Bên cạnh đó, đầu ra của mô hình XGBoost là xác suất dự báo, do đó nghiên cứu không chỉ đánh giá khả năng phân loại đúng mà còn xem xét chất lượng của xác suất dự báo.

7.1. Accuracy

Accuracy đo tỷ lệ dự báo đúng trên tổng số quan sát:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

trong đó TP , TN , FP , FN lần lượt là số trường hợp dự báo True Positive, False Positive, True Negative, False Negative.

Chỉ số này cho biết mức độ dự báo đúng tổng thể của mô hình. Tuy nhiên, accuracy không phản ánh đầy đủ bản chất sai số trong từng nhóm dự báo, vì vậy cần được xem xét cùng với các chỉ số khác.

7.2. Log-loss

Do đầu ra của mô hình là xác suất, nghiên cứu sử dụng thêm log-loss để đánh giá chất lượng xác suất dự báo:

$$LogLoss = -\frac{1}{N} \sum_{i=1}^N [y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)]$$

trong đó y_i là nhãn thực tế của quan sát thứ i , còn p_i là xác suất mô hình dự báo cho lớp dương.

Giá trị log-loss càng thấp cho thấy xác suất dự báo càng phù hợp với kết quả thực tế. Đây là chỉ tiêu quan trọng trong trường hợp đầu ra của mô hình không chỉ được dùng để gán nhãn, mà còn được chuyển thành tín hiệu giao dịch dựa trên ngưỡng xác suất.

7.3. Precision

Precision đo lường mức độ chính xác của các tín hiệu dự báo dương:

$$Precision = \frac{TP}{TP + FP}$$

Chỉ số này cho biết trong tất cả các trường hợp mô hình dự báo giá sẽ tăng, có bao nhiêu trường hợp thực sự tăng. Trong bối cảnh giao dịch, precision cao giúp hạn chế việc vào lệnh sai.

7.4. Recall

Recall đo lường khả năng phát hiện đúng các trường hợp dương thực sự:

$$Recall = \frac{TP}{TP + FN}$$

Chỉ số này cho biết trong tất cả các trường hợp giá thực sự tăng, mô hình nhận diện được bao nhiêu trường hợp. Trong ứng dụng giao dịch, recall cao giúp giảm nguy cơ bỏ lỡ cơ hội thị trường.

7.5. F1-score

F1-score là trung bình điều hòa giữa precision và recall:

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Chỉ số này đặc biệt hữu ích khi cần đánh giá sự cân bằng giữa khả năng phát hiện tín hiệu và độ chính xác của tín hiệu. Trong nghiên cứu này, F1-score được sử dụng để bổ sung cho accuracy, giúp đánh giá mô hình toàn diện hơn.

7.6. Confusion Matrix

Bên cạnh các chỉ tiêu định lượng, nghiên cứu còn sử dụng confusion matrix để quan sát trực quan cấu trúc đúng – sai của mô hình. Ma trận này phân chia kết quả dự báo thành bốn nhóm: dương đúng, âm đúng, dương sai và âm sai. Từ confusion matrix, có thể nhận diện mô hình đang có xu hướng mắc lỗi theo hướng nào, ví dụ dự báo tăng quá nhiều hay bỏ sót các trường hợp tăng thực sự.

Việc kết hợp confusion matrix với precision, recall và F1-score giúp đánh giá đầy đủ hơn chất lượng tín hiệu đầu ra trước khi chuyển sang bước xây dựng chiến lược giao dịch.

8. Thiết kế chiến lược giao dịch

Đầu ra của XGBoost là xác suất tăng giá trong nền kế tiếp. Thay vì sử dụng nhãn dự báo cứng, nhóm nghiên cứu thực hiện chuyển trực tiếp xác suất này thành logic giao dịch để tận dụng độ tự tin của mô hình. Cụ thể như sau:

Trước hết, nhóm nghiên cứu đặt ra các thông số chiến lược:

a) Cấu hình bot chiến lược:

* Logic mua: Nếu position đang là 0:

1. Ngưỡng mua: THRESHOLD_BUY=0.51

2. Đường xu hướng dài hạn: SMA_WINDOW=150 (~3 ngày giao dịch) : đường trung bình động giá đóng cửa 150 phiên trước đó.

Khi model trả về xác suất tăng giá lớn hơn 51%, kết hợp với điều kiện giá đóng cửa đang cao hơn đường SMA 150, hệ thống sẽ thực hiện lệnh mua ALL-IN. Việc lựa chọn ngưỡng 0.51 giúp hệ thống đủ nhạy bén để bắt kịp các nhịp tăng trưởng sớm ngay khi xu hướng vừa hình thành, tránh việc bỏ lỡ các cơ hội "Golden Entry" trong môi trường giá lên (Uptrend).

Ngoài ra, hệ thống tích hợp cơ chế bắt đáy (Counter-trend) đặc biệt: nếu model cực kỳ tự tin với xác suất dự báo tăng vượt 75%, lệnh mua sẽ được kích hoạt bất chấp trạng thái của giá đóng cửa so với đường xu hướng SMA 150.

Logic mua được thể hiện qua đoạn code sau:

```
# --- LOGIC MUA (ENTRY) ---
if position == 0:
    # Điều kiện 1: Giá nằm trên đường xu hướng (Trend Following)
    trend_ok = (price > sma_trend) if not np.isnan(sma_trend) else False

    # Điều kiện 2: AI đồng thuận (> 51%) VÀ Trend tốt
    # HOẶC: AI cực kỳ tự tin (> 75%) thì cho phép bắt đáy (Counter-trend)
    if (prob > THRESHOLD_BUY and trend_ok) or (prob > 0.75):
        position = (capital * (1 - FEE_PCT)) / price # All-in
        capital = 0
        entry_price = price
        highest_price = price
        trade_log.append({'Time': current_time, 'Type': 'BUY', 'Price': price})
```

* Logic bán: Nếu position đang là 1

3. Ngưỡng bán: THRESHOLD_SELL=0.4

Nhằm khắc phục nhược điểm "bán non" trong các đợt rung lắc ngắn hạn (Whipsaw), hệ thống áp dụng ngưỡng thoát lệnh ở mức 40%. Điều này tạo ra một biên độ an toàn: ngay cả khi xác suất tăng dự báo giảm nhẹ xuống 45%, lệnh vẫn được giữ nguyên. Chỉ khi mô hình nhận định rủi ro đảo chiều cao (xác suất giảm xuống dưới 40%) kèm theo việc gãy xu hướng (giá dưới SMA 150), vị thế mới bị thanh lý. Đặc biệt, hệ thống tích hợp tính năng Gồng lãi (Smart Hold): Hủy bỏ mọi tín hiệu bán nếu AI duy trì mức độ tự tin cao (xác suất dự báo tăng > 70%), đảm bảo tối đa hóa lợi nhuận trong các chu kỳ tăng trưởng mạnh.

Logic bán được thể hiện qua đoạn code sau:

```
# --- LOGIC BÁN (EXIT) ---
elif position > 0:
    # Cập nhật đỉnh giá cao nhất
    if price > highest_price: highest_price = price

    # Tính lãi/lỗ
    pnl_pct = (price - entry_price) / entry_price
    drop_from_peak = (highest_price - price) / highest_price

    should_sell = False
    reason = ""

    # === TÍNH NĂNG SMART HODL ===
    # Nếu AI vẫn tự tin (> 70%) -> HỦY LỆNH BÁN. Gồng tiếp bất chấp rung lắc.
    is_strong_uptrend = (prob > 0.70)
```

b) Quản trị rủi ro:

4. Cắt lỗ cứng (STOP LOSS): $SL_PCT=0.08$: Lớp phòng thủ cuối cùng. Nếu vị thế giao dịch ghi nhận mức sụt giảm 8% so với giá vốn (Entry Price), hệ thống sẽ ngay lập tức cắt lỗ vô điều kiện để bảo vệ 92% nguồn vốn còn lại. Nguyên tắc: "Chạm là cắt, không gồng lỗ".

5. Bảo vệ lợi nhuận (TRAILING STOP): $TRAILING_STOP_PCT=0.12$: Khi lệnh giao dịch đã đạt mức lợi nhuận tối thiểu là 5% ($ACTIVE_TRAILING=0.05$), Trailing Stop sẽ được kích hoạt. Từ đỉnh giá cao nhất được ghi nhận (Highest Price), nếu giá đảo chiều giảm mạnh và mất đi 12%, hệ thống sẽ thực hiện chốt lời ngay lập tức. Mức bù trừ 12% được tính toán nhằm tạo ra một "khoảng thở" cần thiết, giúp vị thế không bị đóng oan bởi các nhịp rũ bỏ thị trường (shake-out) thông thường của ETH (thường dao động quanh mức 10%) trước khi tiếp tục chu kỳ tăng.

Quản trị rủi ro được thể hiện qua đoạn code sau:

```
# 1. Cắt lỗ cứng (Hard SL)
if pnl_pct <= -SL_PCT:
    should_sell = True; reason = "Hard SL (Cắt lỗ)"

# 2. Chốt lời động (Trailing Stop)
elif pnl_pct > ACTIVATE_TRAILING and drop_from_peak >= TRAILING_STOP_PCT:
    should_sell = True; reason = "Trailing Stop (Chốt lời)"

# 3. Thoát lệnh khi gãy Trend + AI xấu
elif price < sma_trend and prob < THRESHOLD_SELL:
    should_sell = True; reason = "Trend Broken + Weak Signal"
```

8.1. Tránh look-ahead bias

Một nguyên tắc quan trọng trong mọi backtest là tín hiệu phát tại thời điểm t chỉ được phép trở thành vị thế ở thời điểm $t+1$. Nếu dùng cùng một nền để vừa tạo tín hiệu vừa tính lợi nhuận thì kết quả sẽ bị thiên lệch lạc quan. Vì vậy, trong cách tính vectorized, vị thế luôn được dịch sang kỳ sau bằng hàm `shift()`.

9. Phương pháp backtest và chỉ tiêu tài chính

Nghiên cứu sử dụng backtest event-driven vì chiến lược có trạng thái phụ thuộc vào đường đi giá, đặc biệt là trailing stop. Backtest được khởi tạo với 10.000 USDT vốn ban đầu và chi phí giao dịch 0,1% cho mỗi lần vào hoặc ra lệnh.

9.1. Tổng lợi nhuận và giá trị tài khoản

Giá trị tài khoản tại thời điểm t được cập nhật theo lợi nhuận giao dịch tích lũy. Tổng lợi nhuận được tính bởi:

$$Total\ Return = \frac{Final\ Equity}{Initial\ Cash} - 1$$

9.2. CAGR

CAGR phản ánh tốc độ tăng trưởng kép hàng năm của chiến lược:

$$CAGR = \frac{Final\ Equity}{Initial\ Cash^{\frac{Periods\ per\ year}{T}}} - 1$$

9.3. Sharpe Ratio

Sharpe Ratio đo lợi nhuận vượt trội trên mỗi đơn vị biến động:

$$Sharpe = \frac{mean(r_s)}{std(r_s)} \times \sqrt{M}$$

trong đó r_s là chuỗi lợi nhuận của chiến lược và M là số chu kỳ trong một năm.

9.4. Maximum Drawdown

Maximum Drawdown đo lường mức tổn thất lớn nhất (tính theo phần trăm) từ đỉnh vốn cao nhất (Peak) xuống điểm đáy thấp nhất (Trough) trước khi tài khoản lập đỉnh mới. Chỉ số này phản ánh "khả năng chịu đựng rủi ro" của chiến lược trong kịch bản thị trường tồi tệ nhất.

Công thức tính toán:

Bước 1: Tính toán tỷ lệ sụt giảm tại từng thời điểm t (Drawdown):

$$Drawdown_t = \frac{Equity_t}{\max(Equity_0, \dots, Equity_1)} - 1$$

Bước 2: Tìm mức sụt giảm lớn nhất trong toàn bộ chu kỳ :

$$Maximum_{Drawdown} = \min (Drawdown_t)$$

9.5. Win Rate

Win Rate thước đo thống kê phản ánh xác suất thành công của các quyết định giao dịch. Chỉ số này được xác định bằng tỷ lệ phần trăm giữa số lượng vị thế được tất toán có lợi nhuận trên tổng số vị thế giao dịch đã đóng.

Công thức tính toán:

$$Win\ Rate = \frac{Số\ giao\ dịch\ có\ lãi}{Tổng\ số\ giao\ dịch} \times 100\%$$

IV. KẾT QUẢ NGHIÊN CỨU

1. Kết quả kiểm định dữ liệu và đặc trưng

1.1. Kết quả kiểm định Jarque–Bera và Augmented Dickey–Fuller

Phù hợp với phần dữ liệu và tiền xử lý đã trình bày trước đó, nghiên cứu trước hết kiểm tra đặc điểm phân phối của chuỗi log-return và tính dừng của các biến đầu vào. Đây là bước quan trọng để đánh giá liệu dữ liệu có phù hợp với việc xây dựng mô hình phân loại hay không, đồng

thời kiểm chứng hiệu quả của quá trình feature engineering đã thiết kế ở phần phương pháp nghiên cứu.

Kết quả kiểm định Jarque–Bera cho chuỗi log-return của ETHUSDT cho thấy dữ liệu không tuân theo phân phối chuẩn. Giá trị thống kê JB đạt 10.021.259,32 và p-value xấp xỉ bằng 0, nhỏ hơn rất nhiều so với mức ý nghĩa 5%. Như vậy, có thể bác bỏ giả thuyết chuỗi lợi suất có phân phối chuẩn. Kết quả này xác nhận dữ liệu ETHUSDT ở tần suất 30 phút mang đặc trưng đuôi dày và chứa nhiều biến động cực đoan, đúng với bản chất thường thấy của dữ liệu tài chính ngắn hạn.

Bảng 4.1. Kết quả kiểm định Jarque–Bera đối với chuỗi log-return

Chỉ tiêu	Giá trị
JB Statistic	10.021.259,32
p-value	0,0000
Kết luận	Bác bỏ H_0 ; log-return không tuân theo phân phối chuẩn

Bên cạnh kiểm định phân phối, nghiên cứu tiếp tục áp dụng kiểm định Augmented Dickey–Fuller (ADF) để đánh giá tính dừng của chuỗi giá gốc và các đặc trưng đã biến đổi. Kết quả cho thấy chuỗi giá đóng cửa không đáp ứng tốt điều kiện dừng, trong khi hầu hết các đặc trưng kỹ thuật quan trọng đều vượt kiểm định ở mức ý nghĩa 5%. Điều này hàm ý rằng việc sử dụng trực tiếp mức giá đóng cửa làm đầu vào để huấn luyện mô hình học phải xu hướng dài hạn hoặc quan hệ giá; ngược lại, khi chuyển sang các đặc trưng phản ánh động lượng, xu hướng, biến động và thanh khoản, đầu vào của mô hình trở nên phù hợp hơn về mặt thống kê.

Bảng 4.2. Kết quả kiểm định ADF cho chuỗi giá gốc và các đặc trưng chính

Biến	ADF Statistic	p-value	Kết quả
close	-1,54	0,5137	FAIL
volume	-111,11	0,0000	PASS
Returns	-228,65	0,0000	PASS
RSI	-67,40	0,0000	PASS
PPO	-49,81	0,0000	PASS
PPO_Hist	-90,78	0,0000	PASS
BB_PctB	-84,65	0,0000	PASS
ATR_Pct	-28,36	0,0000	PASS
Vol_Ratio	-154,71	0,0000	PASS
Returns_Lag1	-228,65	0,0000	PASS
RSI_Lag1	-67,41	0,0000	PASS
PPO_Hist_Lag1	-90,80	0,0000	PASS

Tổng hợp lại, kết quả JB và ADF cung cấp bằng chứng khá rõ ràng hướng tiếp cận của nghiên cứu là phù hợp: thay vì làm việc trực tiếp với chuỗi giá gốc không dừng và có phân phối không chuẩn, mô hình được xây dựng trên các đặc trưng đã biến đổi, có nền tảng thống kê tốt hơn và phù hợp hơn với mục tiêu dự báo xu hướng giá ngắn hạn.

1.2. Kết quả sàng lọc đặc trưng và quy mô dữ liệu sau xử lý

Sau bước feature engineering, tập dữ liệu tăng từ 6 biến gốc lên 27 cột, bao gồm giá, khối lượng, biến mục tiêu và toàn bộ các đặc trưng kỹ thuật. Số quan sát sau xử lý còn 100.201 dòng, tức chỉ giảm 21 dòng so với dữ liệu ban đầu. Phần dữ liệu bị loại bỏ chủ yếu phát sinh từ rolling window và các biến trễ, hoàn toàn phù hợp với thiết kế ở phần phương pháp nghiên cứu. Điều này cho thấy nghiên cứu vẫn giữ lại gần như toàn bộ chiều dài chuỗi dữ liệu, đồng thời bổ sung được một tập biến đầu vào giàu thông tin hơn đáng kể so với dữ liệu gốc.

Bảng 4.3. Quy mô dữ liệu trước và sau quá trình xử lý

Chỉ tiêu	Giá trị
Số dòng dữ liệu gốc	100.222
Số dòng sau feature engineering	100.201
Số dòng bị loại bỏ	21
Tổng số cột sau xử lý	27

Kết quả kiểm tra tương quan giữa các feature cũng cho thấy tồn tại một số cặp biến có quan hệ khá chặt, nhưng không ở mức làm mất hoàn toàn giá trị bổ sung của từng nhóm đặc trưng. Từ góc độ thực nghiệm, điều này xác nhận rằng tập đặc trưng được xây dựng không phải là một tập hợp ngẫu nhiên của nhiều chỉ báo kỹ thuật, mà là một hệ thống biến có tính hỗ trợ lẫn nhau, đủ điều kiện để chuyển sang giai đoạn mô hình hóa.

2. Kết quả mô hình phân loại

2.1. Kết quả của mô hình Logistic Regression và XGBoost

Mô hình Logistic Regression được sử dụng như baseline để kiểm tra xem tập đặc trưng kỹ thuật có chứa tín hiệu dự báo ở mức tuyến tính hay không. Kết quả cho thấy Logistic Regression đạt accuracy 53,55% trên tập huấn luyện và 52,89% trên tập kiểm tra. Điều này cho thấy các đặc trưng đầu vào thực sự có chứa tín hiệu, nhưng cấu trúc quan hệ giữa biến đầu vào và biến mục tiêu chưa đủ đơn giản để một biên quyết định tuyến tính có thể khai thác trọn vẹn.

Khi chuyển sang XGBoost – mô hình mở rộng có khả năng học quan hệ phi tuyến – chất lượng dự báo được cải thiện thêm. Mô hình đạt accuracy 56,71% trên tập huấn luyện và 53,54% trên tập kiểm tra; log-loss train/test lần lượt là 0,6804 và 0,6903. Mức chênh lệch giữa train và test khá nhỏ, cho thấy mô hình chưa xuất hiện dấu hiệu overfit nghiêm trọng. Trong bối cảnh dữ liệu tài chính ngắn hạn có độ nhiễu cao, mức cải thiện này là đáng chú ý vì nó tạo ra đầu ra xác suất có chất lượng đủ tốt để tiếp tục sử dụng trong hệ thống giao dịch ở bước sau.

Bảng 4.4. Kết quả so sánh hai mô hình phân loại

Mô hình	Accuracy train	Accuracy test	Log-loss train	Log-loss test
Logistic Regression	53,55%	52,89%	—	—
XGBoost	56,71%	53,54%	0,6804	0,6903


2.2. Kết quả confusion matrix và các chỉ số đánh giá bổ sung

Bên cạnh accuracy và log-loss, nghiên cứu còn đánh giá XGBoost thông qua confusion matrix cùng các chỉ số precision, recall và F1-score. Ma trận nhầm lẫn cho thấy mô hình dự báo đúng 7.141 trường hợp lớp giảm (True Negative) và 8.928 trường hợp lớp tăng (True Positive), đồng thời dự báo sai 7.538 trường hợp tăng giả (False Positive) và 6.404 trường hợp bỏ sót xu hướng tăng (False Negative).

Từ confusion matrix, mô hình đạt precision 0,5422, recall 0,5823 và F1-score 0,5615. Điều này hàm ý rằng XGBoost có khả năng nhận diện các trường hợp giá tăng ở mức tương đối khá, nhưng vẫn tồn tại một tỷ lệ đáng kể tín hiệu sai. Trong bối cảnh giao dịch long/flat, đây là kết quả chấp nhận được, bởi chiến lược không sử dụng nhãn phân loại cứng mà tiếp tục lọc tín hiệu thông qua xác suất, bộ lọc xu hướng và cơ chế quản trị rủi ro ở các bước sau.

Bảng 4.5. Các chỉ số đánh giá phân loại bổ sung của XGBoost trên tập kiểm tra

Chỉ số	Giá trị
Precision	0,5422
Recall	0,5823
F1-score	0,5615
Support lớp 0	14.679
Support lớp 1	15.332



Hình 4.1. Confusion Matrix của mô hình XGBoost trên tập kiểm tra

Nhìn tổng thể, phần kết quả mô hình cho thấy Logistic Regression đã hoàn thành vai trò baseline, còn XGBoost tạo ra xác suất dự báo tốt hơn ở mức vừa phải. Giá trị quan trọng nhất của bước này không nằm ở việc accuracy tăng bao nhiêu điểm phần trăm, mà ở chỗ mô hình đã tạo được tín hiệu đầu ra đủ ổn định để đưa vào phần thiết kế chiến lược giao dịch.

3. Kết quả chiến lược giao dịch Smart HODL

3.1. Kết quả backtest tổng quát

Trên cơ sở xác suất dự báo từ XGBoost, nghiên cứu triển khai chiến lược Smart HODL với ngưỡng mua 0,51, bộ lọc xu hướng bằng SMA 150, stop-loss 8% và trailing stop 12%. Kết quả backtest trên tập kiểm tra cho thấy chiến lược đạt Final Equity 34.481 USDT từ vốn ban đầu 10.000 USDT, tương ứng Total Return 244,81% và CAGR 105,98%. Về mặt rủi ro, chiến lược đạt Sharpe Ratio 1,56 và Maximum Drawdown -56,99%. Đồng thời, chiến lược thực hiện 70 lệnh đóng với Win Rate 47,14%.


Một điểm quan trọng của kết quả này là Win Rate không quá cao nhưng chiến lược vẫn tạo ra lợi nhuận mạnh. Điều đó cho thấy hiệu quả của Smart HODL không đến từ việc dự báo đúng đa số giao dịch, mà đến từ việc giữ được những lệnh thuận lợi đủ lâu và cắt lỗ tương đối sớm khi điều kiện không còn phù hợp. Kết quả này bám rất sát logic đã xây dựng trong phần phương pháp nghiên cứu.

Bảng 4.6. So sánh hiệu quả Smart HODL và Buy & Hold trên tập kiểm tra

Chỉ tiêu	Smart HODL	Buy & Hold
Final Equity	34.481 USDT	22.580 USDT
Total Return	244,81%	125,80%
CAGR	105,98%	60,88%
Sharpe Ratio	1,56	1,04
Maximum Drawdown	-56,99%	-65,83%
Số lệnh đóng	70	1
Win Rate	47,14%	100,00%

3.2. Phân tích biểu đồ equity curve và drawdown

So với chiến lược Buy & Hold trên cùng giai đoạn, Smart HODL cho kết quả vượt trội cả về lợi nhuận tuyệt đối lẫn chất lượng lợi nhuận. Buy & Hold chỉ đạt Final Equity 22.580 USDT, tương ứng Total Return 125,80%, CAGR 60,88% và Sharpe Ratio 1,04. Như vậy, chiến lược đề xuất không chỉ tạo lợi nhuận cao hơn mà còn có khả năng kiểm soát rủi ro tốt hơn khi drawdown tối đa thấp hơn benchmark.



Hình 4.2. Đường diễn biến giá trị tài khoản của Smart HODL so với Buy & Hold và biểu đồ drawdown của chiến lược

Biểu đồ equity curve cho thấy trong giai đoạn đầu chiến lược bám khá sát đường tài sản của thị trường, nhưng về sau bắt đầu tách ra rõ hơn, đặc biệt ở những pha tăng mạnh của ETHUSDT. Trong khi đó, biểu đồ drawdown cho thấy Smart HODL vẫn trải qua các giai đoạn

suy giảm đáng kể, song mức sụt giảm tối đa vẫn thấp hơn Buy & Hold. Đây là một kết quả quan trọng về mặt kinh tế: chiến lược không chỉ kiếm được nhiều hơn, mà còn đạt được chất lượng lợi nhuận tốt hơn khi xét trên tương quan lợi nhuận – rủi ro.

Từ góc độ ứng dụng, kết quả backtest minh họa rất rõ một điểm cốt lõi của đề tài: lợi thế dự báo của mô hình có thể không lớn nếu chỉ nhìn vào accuracy, nhưng khi tín hiệu đó được đặt trong một hệ thống giao dịch có ngưỡng xác suất, bộ lọc xu hướng và cơ chế cắt lỗ phù hợp, hiệu quả kinh tế tạo ra lại khá rõ rệt.

4. Kiểm tra độ bền của mô hình và chiến lược

4.1. Kết quả kiểm tra overfit của XGBoost

Kết quả so sánh train/test cho thấy XGBoost có mức chênh lệch tương đối thấp giữa hai tập dữ liệu: accuracy giảm từ 56,71% trên train xuống 53,54% trên test, tương ứng gap 3,16 điểm phần trăm; log-loss tăng từ 0,6804 lên 0,6903, tức chỉ lệch 0,0099. Với dữ liệu tài chính ngắn hạn vốn có mức nhiễu rất cao, mức sai khác này có thể xem là chấp nhận được. Do đó, có thể kết luận mô hình học được tín hiệu có giá trị mà chưa rơi vào tình trạng overfit nghiêm trọng.

Bảng 4.7. Kết quả kiểm tra overfit của mô hình XGBoost


Chỉ tiêu	Train set	Test set	Độ lệch
Accuracy	56,71%	53,54%	3,16%
Log-loss	0,6804	0,6903	0,0099

4.2. Kết quả kiểm tra độ bền tham số của chiến lược

Bên cạnh việc kiểm tra overfit của mô hình, nghiên cứu còn đánh giá độ bền của chiến lược bằng cách quét lưới 63 kịch bản quanh cấu hình gốc, thay đổi đồng thời SMA Window và mức Trailing Stop. Kết quả cho thấy cấu hình gốc SMA 150 – Trailing Stop 12% mang lại lợi nhuận 244,8%, trong khi lợi nhuận trung bình của các vùng lân cận vẫn đạt 198,8%. Điều này cho thấy hiệu quả của chiến lược không chỉ xuất hiện tại đúng một điểm tham số đơn lẻ mà được duy trì tương đối tốt trong một vùng khá rộng.

Bảng 4.8. Tóm tắt kết quả kiểm tra độ bền của chiến lược

Chỉ tiêu	Giá trị
Số kịch bản kiểm tra	63
Lợi nhuận cấu hình gốc (SMA 150, Trail 12%)	244,8%
Lợi nhuận trung bình các vùng lân cận	198,8%
Kết luận	Chiến lược có độ bền tương đối tốt



Hình 4.3. Heatmap lợi nhuận (%) theo SMA Window và Trailing Stop

Quan sát heatmap cho thấy vùng có lợi nhuận cao không bị co cụm tại một điểm duy nhất mà trải rộng tương đối đều ở các cấu hình lân cận. Đây là tín hiệu tích cực về mặt nghiên cứu, vì nó làm giảm khả năng kết quả tốt chỉ đến từ việc tinh chỉnh tham số một cách ngẫu nhiên. Nói cách khác, chiến lược đề xuất có độ ổn định nhất định và không hoàn toàn phụ thuộc vào một bộ tham số quá cực đoan.

5. Đánh giá tổng hợp kết quả nghiên cứu

Tổng hợp toàn bộ phần kết quả có thể rút ra ba nhận định thực nghiệm chính. Thứ nhất, bước tiền xử lý và feature engineering đã tạo ra một tập biến đầu vào có nền tảng thống kê tốt hơn đáng kể so với việc sử dụng trực tiếp chuỗi giá gốc. Điều này được thể hiện rõ qua kiểm định JB, kiểm định ADF và hiệu quả của mô hình baseline.

Thứ hai, XGBoost cho kết quả tốt hơn Logistic Regression cả về accuracy, log-loss lẫn chất lượng tín hiệu đầu ra. Dù mức cải thiện về accuracy không quá lớn, mô hình phi tuyến này đã tạo ra xác suất dự báo đủ tốt để làm đầu vào cho chiến lược giao dịch.

Thứ ba, khi xác suất dự báo được chuyển hóa thành chiến lược Smart HODL với ngưỡng kích hoạt, bộ lọc xu hướng và cơ chế quản trị rủi ro, hiệu quả đầu tư cuối cùng vượt Buy & Hold cả về lợi nhuận lẫn chất lượng lợi nhuận. Đây là kết luận quan trọng nhất của nghiên cứu, vì nó cho thấy cách tiếp cận kết hợp học máy với logic giao dịch có khả năng tạo ra giá trị kinh tế thực tế trên dữ liệu ngoài mẫu.

V. KẾT LUẬN VÀ ĐÁNH GIÁ

1. Kết luận chính của nghiên cứu

Nghiên cứu đã xây dựng được một quy trình tương đối hoàn chỉnh cho bài toán giao dịch định lượng trên ETHUSDT. Quy trình đó bắt đầu từ dữ liệu OHLCV thô, đi qua bước làm sạch và trực quan hóa, tiếp tục với feature engineering và kiểm định tính dừng, sau đó chuyển sang mô hình hóa bằng Logistic Regression và XGBoost, và kết thúc bằng việc biến xác suất dự báo thành chiến lược Smart HODL được backtest trên dữ liệu ngoài mẫu.

Kết quả thực nghiệm cho thấy chỉ dựa trên accuracy thì mô hình không vượt trội quá lớn, nhưng khi đầu ra của mô hình được đặt trong một cơ chế giao dịch hợp lý, chiến lược thu được lại vượt Buy & Hold khá rõ. Điều này đặc biệt quan trọng vì nó phù hợp với mục tiêu thực tiễn của phân tích dữ liệu trong kinh tế và kinh doanh: hỗ trợ ra quyết định chứ không chỉ tối ưu một chỉ tiêu kỹ thuật thuần túy.

2. Đánh giá điểm mạnh của nghiên cứu

Điểm mạnh đầu tiên là nghiên cứu bám sát bản chất chuỗi thời gian tài chính, thể hiện qua cách chia train-test theo thời gian và sử dụng embargo. Điểm mạnh thứ hai là bước feature engineering có nội dung kinh tế rõ ràng thay vì tạo đặc trưng một cách cơ học. Điểm mạnh thứ ba là nghiên cứu không dừng lại ở việc huấn luyện mô hình mà đã xây dựng được một lớp quyết định giao dịch và cơ chế quản trị rủi ro đi kèm. Cuối cùng, việc thực hiện phân tích độ bền tham số giúp kết luận của nghiên cứu thuyết phục hơn.

3. Những điểm còn hạn chế

Bên cạnh kết quả tích cực, nghiên cứu vẫn tồn tại một số hạn chế. Trước hết, việc đánh giá ngoài mẫu hiện mới dựa trên một lần chia train-test, chưa phải walk-forward validation đầy đủ. Thứ hai, mô hình chưa tích hợp chi phí trượt giá (slippage) một cách riêng biệt, trong khi đây là yếu tố quan trọng nếu triển khai thực tế. Thứ ba, tập dữ liệu mới chỉ dựa trên OHLCV, chưa mở rộng sang dữ liệu on-chain, dữ liệu sentiment hoặc biến vĩ mô. Cuối cùng, drawdown của chiến lược dù đã thấp hơn Buy & Hold nhưng vẫn ở mức khá lớn, cho thấy chiến lược còn dư địa cải thiện về kiểm soát rủi ro.

VI. HƯỚNG PHÁT TRIỂN

1. Hoàn thiện quy trình đánh giá ngoài mẫu

Hướng phát triển quan trọng nhất là triển khai walk-forward validation trên nhiều fold theo thời gian. Cách làm này sẽ giúp đánh giá chiến lược trên nhiều trạng thái thị trường khác nhau và giảm rủi ro kết luận dựa trên một split duy nhất.

2. Bổ sung chỉ tiêu đánh giá mô hình

Ngoài accuracy và log-loss, các nghiên cứu tiếp theo có thể bổ sung ROC-AUC, calibration curve để hiểu sâu hơn chất lượng xác suất dự báo của mô hình.

3. Mở rộng tập đặc trưng

Nhóm cần nhắc việc kết hợp thêm dữ liệu ngoài OHLCV, chẳng hạn tin tức thị trường từ mạng xã hội, chỉ báo on-chain, funding rate hoặc các biến đại diện cho trạng thái thị trường chung. Việc mở rộng tập đặc trưng có thể giúp mô hình nhận diện tốt hơn những thay đổi trạng thái.

4. Nâng cấp lớp chiến lược giao dịch

Trong tương lai, chiến lược có thể được mở rộng từ long/flat sang long/short, bổ sung việc phân bổ vốn hợp lý cho mỗi lần vào lệnh giao dịch theo biến động hoặc xác suất dự báo, và tối ưu hóa cơ chế vào/ra lệnh theo mục tiêu rủi ro-lợi nhuận cụ thể, giảm thiểu drawdown.

5. Tiếp cận theo hướng nghiên cứu nhỏ

Nếu phát triển tiếp thành một nghiên cứu chuyên sâu hơn, đề tài có thể bổ sung kiểm định ổn định của feature importance theo từng giai đoạn thị trường, so sánh nhiều mô hình boosting khác nhau như LightGBM hoặc CatBoost, và đưa thêm phân tích kinh tế hành vi vào phần giải thích kết quả.

TÀI LIỆU THAM KHẢO

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>

Đại học Kinh tế Quốc dân. (n.d.). Giáo trình Khoa học dữ liệu trong kinh tế và kinh doanh. Retrieved April 2026, from https://neu.github.io/Sach_Khoa_hoc_du_lieu_python/README.html

Murphy, J. J. (1999). Technical analysis of the financial markets: A comprehensive guide to trading methods and applications. New York Institute of Finance.

Tạp chí Kinh tế - Tài chính Online. (2021, July 19). Áp dụng phương pháp học máy trong nghiên cứu tài chính ứng dụng ở Việt Nam. Tạp chí Kinh tế - Tài chính Online.

<https://tapchikinhte-taichinh.vn/ap-dung-phuong-phap-hoc-may-trong-nghien-cuu-tai-chinh-ung-dung-o-viet-nam-46019.html>

Vũ, T. H. T., Đặng, H. Y., Trần, T. V., Phạm, T. H. Y., & Nguyễn, K. A. (2025). Dự báo giá bitcoin bằng các mô hình học máy. *Journal of Finance & Accounting Research*, 13, 13–17. <https://doi.org/10.71374/jfarv.v25.i296.03>